

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ตลาดคริปโตเคอร์เรนซี (Cryptocurrency Market) เป็นหนึ่งในตลาดการเงินที่มีการเติบโตอย่างรวดเร็ว ในทศวรรษที่ผ่านมา โดยมีคุณลักษณะเฉพาะที่แตกต่างจากตลาดการเงินดั้งเดิม ทั้งในแง่ การซื้อขายต่อเนื่อง 24 ชั่วโมง ความผันผวนสูง (high volatility) และ สภาพคล่อง (liquidity) ที่เปลี่ยนแปลงตลอดเวลา ความผันผวนที่สูงและการเปลี่ยนแปลงของสภาพคล่องส่งผลต่อประสิทธิภาพในการกำหนดราคาของสินทรัพย์ดิจิทัล ซึ่งเป็นปัจจัยสำคัญต่อการลงทุนและการจัดการความเสี่ยงในตลาดคริปโต

Market Maker (MM) จึงมีบทบาทสำคัญในการเพิ่มสภาพคล่อง โดยทำหน้าที่เสนอซื้อ (bid) และเสนอขาย (ask) เพื่อให้ตลาดมีการจับคู่คำสั่งซื้อขายอย่างต่อเนื่องและลดความแตกต่างของราคา (spread) Market Maker ทำกำไรจาก bid-ask spread และต้องบริหารความเสี่ยง inventory เพื่อหลีกเลี่ยงการขาดทุนในภาวะที่ราคาผันผวน

ในอดีต การทำ Market Making อาศัย โมเดลเชิงคณิตศาสตร์แบบดั้งเดิม เช่น Avellaneda-Stoikov (AS) Model ซึ่งสามารถกำหนด bid/ask spread ที่เหมาะสมตามความผันผวนของตลาดและความเสี่ยง inventory ได้ อย่างไรก็ตาม โมเดลดั้งเดิมมีข้อจำกัดเพราะใช้สมมติฐานคงที่ (static assumption) และไม่สามารถปรับตัวตามการเปลี่ยนแปลงของตลาดได้อย่างมีประสิทธิภาพ

ต่อมาได้มีการนำ ปัญญาประดิษฐ์ (AI) โดยเฉพาะ Reinforcement Learning (RL) มาประยุกต์ใช้กับ Market Making RL ช่วยให้ agent เรียนรู้จากประสบการณ์และปรับตัวตามสภาพตลาดแบบ dynamic งานวิจัยของ Spooner et al. (2018) และ Selser et al. (2021) แสดงให้เห็นว่า RL สามารถเพิ่มผลตอบแทนและจัดการความเสี่ยง inventory ได้ดีกว่ากลยุทธ์ heuristic นอกจากนี้ AMSA (2022) ได้พัฒนา Multi-agent RL ที่ agent สามารถเลือกใช้กลยุทธ์ย่อย (sub-strategies) ได้ตาม market regime ซึ่งช่วยเพิ่ม performance ในสภาวะตลาดที่หลากหลาย อย่างไรก็ตาม RL ยังมีข้อจำกัด เช่น ต้อง retrain เมื่อสภาวะตลาดเปลี่ยน, ใช้ข้อมูลเชิงตัวเลขเท่านั้น และ ขาดความสามารถในการให้เหตุผล (Explainability)

ในอีกด้านหนึ่ง โมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) เช่น GPT-4, FinLLaMA, และ FinGPT ได้รับความสนใจอย่างมากในช่วงไม่กี่ปีที่ผ่านมา เนื่องจาก LLM สามารถ เข้าใจข้อมูลเชิงภาษาธรรมชาติ (natural language) และ วิเคราะห์ข้อมูลบริบท (contextual data) ได้ดีกว่าโมเดล AI แบบดั้งเดิม LLM สามารถตีความข่าวสาร, sentiment บน social media, และข้อมูลตลาดอื่นๆ ที่ไม่เป็นโครงสร้าง ซึ่งเป็นสิ่งที่โมเดล RL และ ML แบบดั้งเดิมไม่สามารถทำได้โดยตรง งานวิจัยของ Lopez-Lira (2025) แสดงให้เห็นว่า LLM agent สามารถทำการเทรดและทำ market making ในสภาพตลาดจำลองได้ โดยใช้ทั้ง numerical data และ contextual data เพื่อประกอบการตัดสินใจ

ปัญหา (Problem Statement)

1. RL agent แม้จะปรับตัวได้ แต่ต้อง retrain และไม่สามารถตีความ context ที่ซับซ้อนได้
2. ML agent ที่ใช้ sentiment เป็น feature ก็ยังจำกัดในความสามารถเพราะลดรูปข้อมูล context เป็นเพียงตัวเลข
3. LLM agent มีศักยภาพในการใช้ context เต็มรูปแบบและ reasoning แต่ยังไม่มีกรอบวิธีการ (framework) ที่ใช้ LLM สำหรับ meta-strategy selection ใน Market Making โดยเฉพาะในตลาดคริปโตที่มีความ dynamic สูง

ดังนั้น งานวิจัยนี้จึงเสนอ การประยุกต์ใช้ LLM ในบทบาท “Meta-Strategy Selector” เพื่อเลือกหรือปรับค่าพารามิเตอร์ของกลยุทธ์ Market Making ให้เหมาะสมกับสภาวะตลาด โดยอ้างอิงข้อมูลตลาดเชิงตัวเลขและข้อมูลบริบท (contextual market data) เช่น sentiment, macro events และ performance ของกลยุทธ์ในอดีต การวิจัยนี้จะเปรียบเทียบประสิทธิภาพของ LLM กับกลยุทธ์ baseline เช่น heuristic และ RL เพื่อยืนยันความสามารถของ LLM ในการเพิ่มประสิทธิภาพและการอธิบายการตัดสินใจ (explainability)

1.2 วัตถุประสงค์ของการวิจัย

1. เพื่อพัฒนา Framework ที่ใช้ LLM ในการคัดเลือกกลยุทธ์ Market Making (Meta-Strategy Selection) โดยใช้ข้อมูลตลาดแบบเรียลไทม์
2. เพื่อเปรียบเทียบประสิทธิภาพของ LLM-Selector กับ RL เช่น AMSA (Adaptive Multi-Strategy Market Making Agent)
3. เพื่อประเมินความสามารถของ LLM ในการปรับตัวต่อสภาวะตลาด และ ให้เหตุผล (reasoning) ที่สนับสนุนการเลือกกลยุทธ์

1.3 ขอบเขตของการวิจัย

สินทรัพย์ที่ศึกษา: BTC/USDT ในตลาด Spot และ Futures

1.3.1 ข้อมูลที่ใช้:

1.3.1.1 Numerical Market Data: Order Book (L2), trading volume, volatility, spread, funding rate

1.3.1.2 Contextual Data: sentiment จาก Twitter/Reddit, ข่าวสารตลาด, indicators เช่น RSI และ Bollinger Bands

1.3.2 โมเดลที่ใช้:

1.3.2.1 Baseline (multi-agent RL): AMSA (Adaptive Multi-Strategy Market Making Agent)

1.3.2.2 Proposed: LLM Strategy Selector (GPT-4o, FinLlama, FinGPT)

1.3.3 ช่วงเวลาการทดสอบ

1.3.3.1 Historical data 6–12 เดือน และ backtesting ใน simulator

1.3.4 สภาพแวดล้อมการทดลอง

1.3.4.1 ใช้ market replay (limit order book simulator) และ paper trading บน Binance Testnet

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1.4.1 ได้ โมเดลต้นแบบ (Prototype Framework) ที่รวม LLM ในบทบาท meta-strategy selector สำหรับ Market Making

1.4.2 แสดงให้เห็นว่า LLM สามารถ ใช้ contextual data และ reasoning เพื่อเพิ่มประสิทธิภาพกลยุทธ์การเทรด

1.4.3 สร้างองค์ความรู้ใหม่ในด้าน AI + Finance โดยเฉพาะ Explainable Market Maker

1.4.4 มีศักยภาพต่อยอดสู่ การพัฒนา algorithmic trading system และ DeFi liquidity provision ที่ฉลาดและยืดหยุ่นกว่าวิธีเดิม

บทที่ 2

แนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้อง

2.1 แนวความคิดหรือทฤษฎีที่เกี่ยวข้องที่ใช้ในการวิจัย

งานวิจัยนี้อ้างอิงแนวคิดหลัก 4 ด้านที่เกี่ยวข้องกับ การทำ Market Making แบบปรับตัวได้ และ การใช้โมเดล AI ขั้นสูง ได้แก่ (1) Market Microstructure และ Market Making, (2) โมเดล Avellaneda–Stoikov (2008), (3) ทฤษฎี Reinforcement Learning (RL) และ Multi-Agent RL (AMSA), และ (4) ทฤษฎี Large Language Models (LLMs) สำหรับ Meta-Strategy Selection ซึ่งเป็นองค์ความรู้พื้นฐานในการพัฒนา framework ที่เสนอ

2.1.1 Market Microstructure และ Market Making

Market Microstructure ศึกษากลไกการซื้อขายในตลาดการเงิน โดยเน้นไปที่วิธีการกำหนดราคาและการจัดการคำสั่งซื้อขาย (order flow) ในตลาดแบบ limit order book (LOB) Market Maker (MM) มีหน้าที่สำคัญคือ:

- สร้างสภาพคล่อง (liquidity) โดยการวาง bid และ ask อย่างต่อเนื่อง
- ลด spread และเพิ่มประสิทธิภาพตลาด
- บริหารความเสี่ยง inventory เพื่อป้องกันการขาดทุนจากการถือครองสินทรัพย์

MM ต้องออกแบบกลยุทธ์ที่สมดุลระหว่าง การทำกำไร (PnL) และ การควบคุมความเสี่ยง ในตลาดที่มีความผันผวนสูงอย่างตลาดคริปโต

2.1.2 โมเดล Avellaneda-Stoikov (2008)

โมเดล Avellaneda–Stoikov (AS) เป็นหนึ่งในโมเดลพื้นฐานของ Market Making ที่ใช้ Stochastic Optimal Control เพื่อคำนวณ ราคาที่เหมาะสม (optimal bid/ask quotes) โดยพิจารณา:

- ความผันผวนของราคา (σ)

- inventory ของ market maker (q)

- ระดับความเสี่ยงที่ยอมรับได้ (γ)

สูตรของ AS ช่วยให้ MM สามารถคำนวณ bid/ask spread ที่เหมาะสมตาม market condition แต่มีข้อจำกัดคือ ไม่สามารถปรับตัวต่อภาวะตลาด dynamic และ ไม่ใช้ข้อมูลภายนอก (contextual data)

2.1.3 ทฤษฎี Reinforcement Learning (RL) ใน Market Making

Reinforcement Learning (RL) เป็นวิธีการเรียนรู้ของปัญญาประดิษฐ์ (Artificial Intelligence) ที่ agent เรียนรู้วิธีการตัดสินใจที่เหมาะสมที่สุดผ่านการโต้ตอบกับสภาพแวดล้อม (Environment) โดยมีวัตถุประสงค์เพื่อหานโยบาย (Policy) ที่สามารถ เพิ่มผลตอบแทน (Reward) ในระยะยาว การเรียนรู้ของ RL ไม่ได้อาศัยข้อมูลที่มีป้ายกำกับ (label) แบบ Supervised Learning แต่เกิดจาก การทดลอง (trial-and-error) และการประเมินผลลัพธ์ของการกระทำ (Action) ในแต่ละสถานการณ์ (State)

องค์ประกอบหลักของ RL ประกอบด้วย

- Agent: ตัวแทนที่ทำการตัดสินใจ
- Environment: สภาพแวดล้อมที่ agent โต้ตอบ
- State (s): สถานะของสภาพแวดล้อม ณ เวลานั้น
- Action (a): การกระทำที่ agent เลือกทำ
- Reward (r): ค่าตอบแทนที่ agent ได้รับจากการกระทำ
- Policy (π): กฎที่ agent ใช้กำหนดการเลือก action

2.1.4 ทฤษฎี Multi-Agent RL (AMSA)

Reinforcement Learning (RL) เป็นสาขาของ AI ที่ agent เรียนรู้กลยุทธ์ (policy) ผ่านการโต้ตอบกับ environment โดยพยายาม maximize reward ในระยะยาวโดยมี:

- State (s): ตัวแปรที่บ่งบอกสถานะตลาด เช่น spread, volatility
- Action (a): การปรับ bid/ask หรือเลือกกลยุทธ์
- Reward (r): ผลตอบแทน เช่น PnL หรือ reward ปรับความเสี่ยง
- Policy (π): กฎที่บอกว่า state ไດควรเลือก action ไດ

ใน Market Making RL ช่วยให้ agent เรียนรู้กลยุทธ์ dynamic ที่ปรับตัวได้ตามการเปลี่ยนแปลงของตลาด โดยงานวิจัยจำนวนมากใช้ RL (เช่น DQN, PPO) เพื่อแก้ปัญหา inventory risk และเพิ่มผลตอบแทน แต่ RL มีข้อจำกัดคือ:

- ต้อง retrain เมื่อ market regime เปลี่ยน
- ใช้ numerical features เท่านั้น
- ขาด explainability

AMSA (Adaptive Multi-Strategy Market Making Agent)

AMSA เป็น Multi-Agent RL ที่ meta-agent ทำหน้าที่เลือก sub-strategies (เช่น aggressive, conservative) ตาม market regime

ใช้ การประเมินผลจากทั้ง real trading และ internal backtesting เพื่อคัดเลือกกลยุทธ์ที่เหมาะสมในแต่ละช่วงเวลา

AMSA จึงสามารถปรับตัวได้ดีกว่า RL แบบเดี่ยว (เช่น DQN, PPO) และ outperform heuristic MM

ข้อจำกัด: แม้ AMSA จะเป็น adaptive RL แต่ยังไม่ใช้ข้อมูลบริบท (contextual data) เช่น sentiment, macro events และยังขาด reasoning ที่มนุษย์ตีความได้

2.1.4 ทฤษฎี Large Language Models (LLMs)

Large Language Models (LLMs) เป็นโมเดลปัญญาประดิษฐ์ประเภท Deep Learning ที่ได้รับการฝึก (pre-trained) จากชุดข้อมูลข้อความขนาดใหญ่ โดยอาศัยสถาปัตยกรรม Transformer ซึ่งสามารถประมวลผลลำดับของคำ (sequences) ได้อย่างมีประสิทธิภาพ โมเดลเหล่านี้สามารถทำความเข้าใจและสร้างข้อความ (Natural Language Processing: NLP) ได้ในระดับสูง และสามารถปรับตัว (fine-tune) เพื่อตอบสนองการใช้งานในโดเมนเฉพาะ

2.2 เอกสารและงานวิจัยที่เกี่ยวข้อง

เพื่อสนับสนุนกรอบแนวคิดของงานวิจัยนี้ ได้ทำการศึกษางานวิจัยที่เกี่ยวข้อง 3 เรื่องหลัก ได้แก่:

(1) Spooner et al. (2018) – Market Making via Reinforcement Learning

แนวทาง: ใช้ Temporal-Difference Reinforcement Learning (TD-RL) พัฒนา agent สำหรับ market making

วิธีการ: Agent รับ state (volatility, inventory, spread) → เลือก action → ได้ reward (PnL – inventory risk) → ปรับ policy

ผลการทดลอง: RL agent outperform กลยุทธ์ fixed spread และ heuristic MM

ข้อจำกัด:

ต้อง retrain agent เมื่อ market regime เปลี่ยน

ใช้ numerical features เท่านั้น

ขาดการให้เหตุผล (Explainability)

ความเชื่อมโยงกับงานวิจัยนี้: งานนี้เป็น baseline สำหรับเปรียบเทียบ เนื่องจากใช้ RL แบบดั้งเดิมโดยไม่พิจารณา contextual data

(2) Li et al. (2022) – AMSA: Adaptive Multi-Strategy Market Making Agent

แนวทาง: เสนอ Multi-Agent Reinforcement Learning ที่ meta-agent สามารถเลือก sub-strategies (aggressive, conservative, neutral) ให้เหมาะสมกับสภาวะตลาด

วิธีการ:

Meta-agent เลือก sub-agents ตามผลการ backtest และ real trading performance

Sub-agents ดำเนินกลยุทธ์ตามที่ได้รับเลือก

ผลการทดลอง: AMSA outperform RL agent เดี่ยว (DQN, PPO) และ heuristic MM ในทุกสภาวะตลาด

ข้อจำกัด:

Training ซับซ้อน ใช้ compute สูง

ไม่ใช่ contextual data (ข่าว, sentiment)

ไม่มี reasoning ที่มนุษย์ตีความได้

ความเชื่อมโยงกับงานวิจัยนี้: งานวิจัยของ AMSA มีแนวคิด meta-strategy selection ที่คล้ายกับ LLM-Selector แต่ยังไม่ใช้ contextual reasoning

(3) Lopez-Lira (2025) – Can Large Language Models Trade

แนวทาง: ทดลองใช้ LLM agents (GPT) ใน simulated stock market เพื่อทดสอบการตัดสินใจ trade และ market making

วิธีการ:

LLM รับ market state + ข่าว + sentiment

LLM ตัดสินใจ action (buy/sell/hold) โดย reasoning จาก context

ผลการทดลอง: LLM agents สามารถปรับพฤติกรรมตาม context และ reasoning ได้ดีกว่า heuristic และ ML บางแบบ

ข้อจำกัด:

Latency สูง

ไม่มี parameter optimization แบบ RL

ยังไม่ได้พัฒนา meta-strategy selection สำหรับ MM

ความเชื่อมโยงกับงานวิจัยนี้: งานนี้พิสูจน์ศักยภาพ LLM ใน trading และสนับสนุนการใช้ LLM เป็น meta-agent สำหรับเลือกกลยุทธ์ในตลาดคริปโต

J. Spooner, T. Fearnley, A. Savani, and D. Cliff, "Market Making via Reinforcement Learning," arXiv preprint arXiv:1804.04216, 2018.

S. Li, Y. Xie, and T. Lin, "AMSA: Adaptive Multi-Strategy Market-Making Agent," arXiv preprint arXiv:2204.13265, 2022.

R. Lopez-Lira, "Can Large Language Models Trade? Testing Financial Theories with LLM Agents in Market Simulations," arXiv preprint arXiv:2504.10789, 2025.